

УКРАЇНСЬКИЙ КАТОЛИЦЬКИЙ УНІВЕРСИТЕТ

КУРС «ШТУЧНИЙ ІНТЕЛЕКТ» · СЕМЕСТРОВИЙ ПРОЄКТ · 2026

Бенчмарк детекції дублікатів і навколодублікатів для виявлення координованих інформаційних атак

Команда:

**ТРУШ СОФІЯ
ПЕТРУСЬ ДОМІНІКА**

Ментор:

**КОРЕЦЬ ХРИСТИНА
КОСОВАН ОЛЕКСАНДР**

Репозиторій:

<https://github.com/sofiatrush/benchmark.git>

*Пропозиція проєкту, подана в межах курсу
«Штучний інтелект»*

Факультет прикладних наук



2026-09-21

1. Проблема та мотивація

У Telegram одна й та сама інформація швидко поширюється між каналами в ідентичному або зміненому формулюванні. Для автоматичного аналізу такого контенту важливо розрізняти exact duplicate (однаковий текст), near-duplicate (той самий зміст із перефразуванням чи дрібними змінами) та different (різні тексти). Просте порівняння не завжди виявляє перефразування, а семантично схожі тексти можуть помилково визначатися як дублікати.

У контексті III ця задача цікава тим, що дозволяє порівняти різні підходи до визначення схожості текстів на однакових даних і за єдиними критеріями. Окрім цього повторюване поширення однакового або дуже схожого контенту між каналами може бути сигналом координованої інформаційної атаки. Тому важливо зрозуміти, у яких випадках різні методи помиляються.

2. Огляд джерел та наявних рішень

Існують різні підходи до порівняння текстів, найпростіші з них спираються на слова, символи або короткі фрагменти. Наприклад, TF-IDF подає тексти як числові вектори, схожість яких визначають за допомогою cosine similarity [1]. Його можна застосовувати до слів та до символічних n-грам.

У роботі Broder [2] розглядається задача визначення схожості документів, на основі якої розвивалися методи MinHash та LSH. Вони дозволяють швидше знаходити схожі документи у великих наборах даних. А Gyawali et al. [3] досліджують їх використання разом з векторними представленнями тексту для виявлення дублікатів і близьких за змістом документів.

Інший напрям пов'язаний із семантичним порівнянням текстів. Reimers та Gurevych [4] запропонували Sentence-BERT, який перетворює речення на вектори та дозволяє визначати близькість текстів за змістом. На основі цього підходу з'явилися різні мультимовні моделі, зокрема multilingual-E5 [5] та BGE-M3 [6]. Zhang et al. [7] також запропонували сучасний підхід RETSim для пошуку близьких текстів і виявлення навколодублікатів. Окремо існують роботи, що розглядають цю задачу в контексті Telegram. Blas et al. [8] досліджують виявлення координованої активності через схожість.

Для оцінювання таких методів прикладом є benchmark NEWS-COPY [9], у якому різні підходи порівнюються на розмічених даних під єдиним протоколом.

3. Дані

Ми використаємо Aisberg Telegram News UA dataset [10], доступний за ліцензією CC BY 4.0. Він налічує понад 200 тисяч деідентифікованих Telegram-постів із метаданими з 27-и українських новинних каналів. Датасет містить тексти переважно українською, але також російською та англійською мовами. Пости згруповані в кластери, кожен з яких описує одну подію.

Для створення benchmark, ми відберемо лише частину україномовних текстів, з якої сформуємо близько 3–5 тис. пар з використанням кластерів, щоб збільшити частку потенційних позитивних прикладів. Після чого вручну розмітимо три класи: exact duplicate, near-duplicate та different, з контрольованим співвідношенням класів, щоб уникнути дисбалансу. Розмічені пари розділимо на тестову та валідаційну вибірки.

4. Підхід і методи

Ми плануємо побудувати бенчмарк, який буде порівнювати лексичні та семантичні методи виявлення однакового тексту у різних формулюваннях. У кожній з двох груп тестуємо кілька методів і порівнюємо їх за якістю та обчислювальною вартістю.

Лексичні методи:

- TF-IDF - перетворює тексти на числові вектори, враховуючи частоту tokenів та їхню рідкість у корпусі, порівнює вектори через cosine similarity. Токени будемо визначати кількома способами: слова, 3-,4-,5-грами.

- MinHash and LSH. Цей метод розбиває текст на невеликі фрагменти. MinHash створює з них відбиток (набір чисел, що замінює повний текст), а LSH використовує їх, щоб швидко знаходити потенційно схожі тексти без прямого порівняння кожної пари.

Семантичні методи:

- paraphrase-multilingual-MiniLM (мультимовна модель Sentence-Bert). Перетворює кожен пост на числовий вектор, який містить інформацію про його семантичний зміст та порівнює їх. Цей метод дасть змогу знаходити перефразування, які можуть бути непомітними для попередніх методів.
- Multilingual-e5 (base). Так само перетворює текст на вектор, проте вона навчена на мільярді пар природно пов'язаних текстів [5]. Для її використання перед кожним текстом потрібно буде додати спеціальний префікс.
- BGE-M3. Так само перетворює текст на вектор, але це найбільша з трьох моделей за кількістю параметрів. Вона дасть змогу оцінити, скільки якості додає важча модель порівняно з легшими.

Усі методи реалізовуватимемо на основі відкритих бібліотек, не змінюючи алгоритмів, а лише адаптуючи параметри. Кожен метод повертає для пари текстів число, яке показує ступінь схожості (чим вище значення, тим більша схожість). Оскільки в нас три класи, для кожного методу підберемо два пороги на валідаційній вибірці, а фінальні метрики мірятимемо на тестовій.

Наприкінці перевіримо найкращий метод на нерозмічених постах, щоб подивитися, чи можна за його допомогою виявити координацію між каналами.

5. Оцінювання результатів

Усі методи будемо оцінювати на одному й тому самому наборі тестових пар за однаковими метриками. Для кожного методу порахуємо Precision, Recall та F1 окремо для класу exact-dup і окремо для near-dup, бо метод може добре знаходити точні копії, але пропускати перефразування, або навпаки. Бейзлайном для лексичних методів буде TF-IDF з cosine similarity, а для семантичних paraphrase-multilingual-MiniLM. Інші методи відповідно порівнюватимемо з ними. Замірятимемо також час роботи та використання пам'яті на зростаючих обсягах даних. Методи порівняємо на кількох графіках якості vs вартість. На нерозмічених даних міряємо лише вартість. Також проаналізуємо пари, на яких методи помиляються. Очікуємо, що лексичні методи пропускатимуть перефрази із заміною слів, а семантичні плутатимуться на дуже коротких постах і через підпис чи посилання в кінці тексту.

6. План і ризики

Роботу над проектом плануємо виконати у такі етапи: до мідтерму завершимо підготовку даних, формування пар, основну частину розмітки та підготуємо реалізації всіх методів. Після нього зосередимося на підборі параметрів, оцінюванні методів на тестових даних, замірах часу й аналізі помилок. На фінальному етапі узагальнимо результати, сформулюємо висновки та підготуємо постер.

Ризики проекту:

- Обсяг ручної розмітки: розмітка 3-5 тисяч пар займе багато часу.
- Дисбаланс класів: кластер об'єднує пости за темою події, а не за схожістю тексту, тому не всі пари будуть дублікатами. Якщо після розмітки exact-dup та near-dup виявиться замало, оцінка методів на цих класах буде неточною.
- Велика кількість методів: підбір порогів і заміри часу для всіх методів займуть багато часу, а семантична модель BGE-M3 може потребувати GPU.

7. Contribution statement

- Труш Софія — підготовка даних, семантичні методи, оцінювання результатів
- Петрусь Домініка — підготовка даних, лексичні методи, оцінювання результатів

Список джерел

- [1] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 1988. URL: <https://ecommons.cornell.edu/entities/publication/d81a71f9-8de9-4ef1-9ee2-8544cdb48372>.
- [2] Andrei Z. Broder. On the resemblance and containment of documents. In *Proceedings of Compression and Complexity of Sequences*, 1997. URL: https://www.researchgate.net/publication/262333747_On_the_Resemblance_and_Containment_of_Documents.
- [3] Bikash Gyawali, Lucas Anastasiou, and Petr Knuth. Deduplication of scholarly documents using locality sensitive hashing and word embeddings. In *Proceedings of the Twelfth Language Resources and Evaluation Conference (LREC)*, 2020. URL: <https://aclanthology.org/2020.lrec-1.113>.
- [4] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019. URL: <https://arxiv.org/abs/1908.10084>.
- [5] multilingual-e5-base model card. URL: <https://huggingface.co/intfloat/multilingual-e5-base>.
- [6] BAAI. BGE-M3 model card, 2024. URL: <https://huggingface.co/BAAI/bge-m3>.
- [7] Marina Zhang, Owen Vallis, Aysegul Bumin, Tanay Vakharia, and Elie Bursztein. RETSim: Resilient and efficient text similarity. In *International Conference on Learning Representations (ICLR)*, 2024. URL: https://proceedings.iclr.cc/paper_files/paper/2024/file/194d93e09eabcb9e2837de07d0be48ce-Paper-Conference.pdf.
- [8] Leonardo Blas, Diya Saraf, Tanishq Salkar, Nora Adadurova, Luca Luceri, and Emilio Ferrara. Large-scale detection of multilingual coordinated activity on Telegram. *npj Complexity*, 2025. URL: <https://www.nature.com/articles/s44260-025-00056-w>.
- [9] Emily Silcock, Luca D’Amico-Wong, Jinglin Yang, and Melissa Dell. Noise-robust de-duplication at scale. In *International Conference on Learning Representations*, 2023. URL: <https://openreview.net/forum?id=bAz2DBS35i>.
- [10] Aisberg Public Organization. Telegram news ua dataset. URL: <https://huggingface.co/datasets/aisbergpublicorganization/telegram-news-ua-dataset>.